

Financial 10-K RAG

8分钟 Presentation 结构与 Slides 制作指南

用途：帮助组员统一理解项目故事线、时间分配、每页重点、演示策略与视觉规范。

汇报核心	从“模型组合决定质量”到“财报专项代码 + 问题驱动迭代决定可靠性”
最终方案	GPT-5.6 Sol + OpenAI text-embedding-3-large + FAISS
主要证据	十道跨组题调优前后、五模型最终对比、幻觉边界案例
课程	JHU Carey BAAI - AI Essentials

Zhewei Hu · Shuai Yuan · Junwei Lin · Yuhan Ding · Shuying Chen · Qige Wang

1. 一页读懂整场 Presentation

这场汇报不应讲成“我们试了很多模型，Sol 得分最高”，而应讲成一个完整的研究与工程决策过程：

初始假设 → 关键发现 → 问题驱动迭代 → 财报专项架构 → 调优前后验证 → 五模型权衡 → 最终选择

建议总时长：7分30秒内容 + 30秒缓冲。Slides 控制在 9 页。

时间	Slide	核心任务	观众应记住的结论
0:00-0:35	1. Goal	问题与成功标准	目标不是流畅，而是准确、完整、可溯源
0:35-1:15	2. Initial Hypothesis	早期组合实验	最初以为 LLM/Embedding/参数决定质量
1:15-2:00	3. Key Discovery	项目转折点	财报专项代码比单纯换模型更重要
2:00-3:00	4. Iteration	问题驱动闭环	问题指导通用改进，但答案不硬编码
3:00-3:55	5. Architecture	最终 RAG 设计	完整证据进入上下文是可靠答案的前提
3:55-5:05	6. Before vs. After	十题调优前后	改善集中在检索完整度，不是算术能力
5:05-6:00	7. Trade-off	五模型最终对比	Sol 最大化质量；Luna 优化成本与速度
6:00-7:15	8. Demo & Boundary	强项题与错误前提	系统会纠正前提并承认证据边界
7:15-8:00	9. Conclusion	选择、局限、挑战题	可靠 RAG = 模型 + 检索 + 边界控制

推荐开场句

“Our goal was not simply to generate fluent answers. The system needed to retrieve the correct company, period, financial caption, unit, and source page.”

2. Slides 1-3：建立问题并制造故事转折

Slide 1 - Project Goal

- 语料只有三份 2025 Form 10-K：Alphabet、Amazon、Microsoft。
- 成功标准：真实性、准确度、严谨性、PDF 页码溯源，以及证据不足时拒绝猜测。
- 页面只放三条目标，不放技术架构。标题应表达结论，例如 “Reliable answers require complete filing evidence”。

Slide 2 - Initial Hypothesis

- 展示早期 V4 组合排名：LLM、Embedding、Chunk Size、Overlap 等被视为主要变量。
- 只保留前几名与大致分数，不逐项解释六种组合。
- 过渡句：“These results were useful, but they mixed model capability with implementation quality.”

Slide 3 - Key Discovery

- 团队开会后发现一位组员版本明显更强；代码审查显示其优势来自财报专项处理。
- 统一财报架构后再分两条路线迭代；Gemini Embedding 的认证问题只用一句话带过。
- 核心结论：“This changed the project from model selection into financial evidence engineering.”

这三页的 Slides 制作建议

应做	避免
使用结论型标题；每页最多三条；早期排名用简化横条图	大段项目背景；完整代码截图；逐一介绍所有模型组合
用同一种颜色表示“初始假设”，用强调色标记“关键发现”	在转折点之前提前展示最终答案，削弱故事张力


推荐转场

“Once we controlled the code, the next question became: how should we improve that code systematically?”

3. Slide 4 : 问题驱动的持续迭代

Question-driven iterative optimization

Failures became reusable financial-evidence rules - never hard-coded answers



Public bank: 62 development · 30 hidden generalization · 15 final unseen holdout · 10 cross-group benchmark

这一页是整场汇报的方法论核心。建议用动画让六个步骤逐个出现，但反馈回路最后一次出现即可。

步骤	讲解重点
Question Bank	覆盖直接事实、计算、跨公司比较、多语言、错误前提、定性问题和不可回答问题。
Batch Testing	使用同一套 RAG 批量运行并保留检索来源、延迟和 Token。
Human Evaluation	人工检查真实性、完整度、计算、引用和边界。
Error Classification	区分 Retrieval、Prompt、PDF/Table Parsing 和 genuinely missing evidence。
General Improvement	把失败转成公司平衡检索、精确财务 Caption、完整表格证据等通用规则。
Regression + New Tests	旧题确保不退步，新题继续扩大边界；代码冻结后才运行 Holdout。


必须明确说出的句子

“The questions guided our improvements, but their answers were never hard-coded into the system.”

4. Slide 5 : 最终财报 RAG 架构

Final financial 10-K RAG architecture

Evidence-first retrieval with fixed, tested parameters



Safety boundary If the filings do not support a claim, the assistant must say so; external facts and investment advice are not inferred.

只解释与可靠性直接相关的设计，不要逐行展示代码。建议按数据流从左到右讲。

模块	汇报时只讲这一点
PDF Processing	保留 Layout，并为表格密集页建立补充文本。
Chunk + Metadata	1,000 字符、150 Overlap；保留 Company、File 和 PDF Page。
Embedding + FAISS	OpenAI text-embedding-3-large；本地索引与 Fingerprint Cache。
Query-aware Retrieval	识别公司和问题类型，跨公司问题保证每家公司都有证据。
Evidence-constrained Prompt	要求期间、单位、公式、比较完整度、错误前提纠正和引用。

推荐解释

“The largest failures did not come from arithmetic. They happened when the required evidence never entered the context window.”

5. Slide 6：十道跨组题的调优前后

不要展示十道完整答案。用四个典型失败证明迭代如何形成通用财报规则，同时说明调优前已经存在的强项。

调优前问题	通用改进	调优后表现
三家公司比较时缺少一家证据	Company-balanced retrieval	获取每家公司完整证据后再排名
Cash tax 缺 numerator 或 denominator	Paired financial evidence	完成三家公司计算并显示输入值
Capex 使用附近的叙述性数字	Exact cash-flow caption preference	使用准确现金流量表项目并披露措辞差异
税率因素遗漏或方向错误	Complete reconciliation + signed factors	保留因素正负号、方向和解释口径

调优前已经表现好的能力

- Microsoft FY2024 Productivity and Business Processes revenue：直接事实准确。
- Beginning cash 与 Cloud margin：证据完整时计算正确。
- 拒绝把 Amazon Technology and infrastructure 与 Microsoft R&D; 直接等同。
- 拒绝仅根据三份 10-K 作出“最佳投资”推荐。

评价方法的诚信说明

十道题用于后续改进后，就不再是完全 unseen 的 generalization test。最终结果应称为 regression/optimization validation；真正的外部检查应使用代码冻结后的 15 道 Holdout。


推荐过渡句

“After improving the retrieval rules, we froze the code and reran five language models to isolate the final model trade-off.”

6. Slide 7：最终五模型 Trade-off

Five-model trade-off on the 10-question benchmark

Direct comparison of accuracy, average latency, and measured API cost



Final choice Sol achieved the only 20/20; Luna was the fastest and cheapest near-equivalent production option.

All costs were computed from the recorded input/output tokens and the prices used during the experiment.

模型	质量	速度/成本	建议定位
GPT-5.6 Sol	唯一 20/20	10.69s；\$0.6707/10题	最终学术提交：最大化完整性与严谨性
GPT-5.6 Luna	19.5/20	5.40s；\$0.1341/10题	商业场景：最强成本/延迟方案
Terra / Sonnet / Fable	均 19.5/20	风格、Token、成本差异明显	作为模型行为与部署取舍证据

建议只讲三点：Sol 的完成度最高；Luna 速度约快一倍且成本约为五分之一；不存在脱离使用目标的“绝对最好模型”。价格必须标注为实验快照。

7. Slides 8-9 : Demo、幻觉边界与结论

Slide 8 - Demo 设计

演示题	展示能力	期望结果
What was Microsoft's Productivity and Business Processes segment revenue for fiscal year 2024?	准确事实、期间、单位和页码引用	\$106.820 billion，并展示来源 Chunk
Can Alphabet's \$24.08B 2025 gains and ~\$32.0B January 2026 unrealized gains simply be added?	纠正错误前提、识别重叠和 realized/unrealized 差异	拒绝机械得出 \$56.08B，并解释证据边界

Demo 风险控制

- 提前保存两道题的答案截图或录屏；现场 API 失败时立即切换，不解释技术故障。
- 演示页面中不显示 API Key；浏览器缩放和字体提前固定。
- 现场只问两题，不临时接受观众提出的新问题，以免超过时间。

Slide 9 - Conclusion

- 财报专项检索设计比单纯更换模型更重要。
- 问题驱动迭代解决了真实长尾错误，同时避免硬编码答案。
- Sol 用于最大化质量；Luna 是成本和速度敏感场景的替代方案。
- 下一步：结构化表格解析、Hybrid Retrieval、Reranker、自动引用验证、冻结后 Holdout。

推荐收尾句

“The best model alone did not create the best financial RAG. The strongest result came from question-driven iteration, financial-specific retrieval, and explicit hallucination boundaries.”

8. Slides 制作规范与协作建议

视觉规范

项目	建议
配色	深蓝 #11263D；主蓝 #2878D1；青绿 #168A83；金色只用于强调 Trade-off。
字体	英文优先 Aptos/Arial；标题 28-32pt；正文 18-22pt；脚注不低于 12pt。
标题	使用结论型标题，例如 “Complete evidence mattered more than arithmetic ability”。
信息密度	每页一个结论、最多三条要点；图表优先；避免完整代码、长 Prompt 和大段答案。
动画	只用于流程逐步出现；不用飞入、旋转或复杂转场。
引用	结果页脚注明 10-question benchmark、human review 和 pricing snapshot。

组内制作流程

- 先由一人建立 Master Slide、颜色、字体和页脚，其他人复制模板，不分别设计风格。
- 每页指定一位内容负责人，但最后由同一人统一精简文字和检查视觉。
- 讲稿按“页面结论 + 证据 + 转场”三句结构编写，不逐字念 Slide。
- 至少进行两次完整计时彩排：第一次修内容，第二次只修节奏和交接。
- 建议最多三次发言人交接；交接句提前写入 Speaker Notes。

最终检查清单

- 总时长不超过 8 分钟；Demo 失败仍能完整讲完。
- 早期模型组合结果与最终五模型结果没有混淆。
- 明确区分调优前、调优后和 protected holdout。
- 不宣称 Gemini Embedding 质量差，只说明本环境认证不稳定。
- 不把十道调优后结果描述为完全 unseen。
- API Key、个人路径和本地文件结构不出现在 Slides。
- 最终 Challenge Question 与答案逻辑已由至少两名组员复核。

最重要的观众记忆点

可靠的财报 RAG 不是单纯选择一个更强模型，而是通过问题驱动迭代，让正确、完整、可比较的财报证据稳定进入模型上下文。